TÀI LIỆU PHÂN TÍCH KIẾN TRÚC HỆ THỐNG

Tên đề tài: Ứng dụng kiến trúc 3 lớp trong xây dựng trợ lý ảo thông minh cho lĩnh vực di sản du lịch và hành chính.

1. Đặt vấn đề

Sự bùng nổ của các Mô hình Ngôn ngữ Lớn (LLM) đã mang lại những bước tiến vượt bậc trong khả năng tương tác tự nhiên giữa người và máy. Tuy nhiên, khi áp dụng vào các lĩnh vực đặc thù đòi hỏi tính chính xác tuyệt đối như lịch sử, di sản văn hóa, và địa giới hành chính tại Việt Nam, các mô hình này thường bộc lộ điểm yếu. Chúng dễ sinh ra hiện tượng "ảo giác" (hallucination) – tự bịa đặt thông tin – hoặc thiếu hụt các dữ liệu mang tính thời điểm và địa phương hóa.

Để giải quyết triệt để vấn đề này, đề tài đề xuất xây dựng một hệ thống Trợ lý ảo đàm thoại thông minh ứng dụng phương pháp **Hệ lai Hiện đại (Hybrid System)**. Giải pháp này kết hợp tư duy logic nghiêm ngặt của Đồ thị tri thức (Knowledge Graph - KG), khả năng tìm kiếm mở rộng của RAG (Retrieval-Augmented Generation) và khả năng sinh ngữ cảnh tự nhiên của LLM.

2. Kiến trúc Hệ thống Cốt lõi

Hệ thống được thiết kế dựa trên kiến trúc 3 lớp bổ trợ lẫn nhau, đảm bảo luồng thông tin đi từ cấu trúc dữ liệu cứng đến ngôn ngữ tự nhiên mềm dẻo.

Thành phần	Công nghệ Triển khai	Chức năng và Nhiệm vụ trọng tâm
Knowledge Graph (KG)	Neo4j, Cypher Query	Lưu trữ thực thể và mối quan hệ đa chiều (ví dụ: Di tích A - thuộc - Tỉnh B). Cung cấp "sự thật cứng" (ground truth) để loại bỏ hoàn toàn rủi ro ảo giác.
RAG & Vector DB	Transformer (Embedding), FAISS	Lập chỉ mục các văn bản phi cấu trúc (bài viết, đánh giá du lịch). Thực hiện tìm kiếm ngữ nghĩa để bổ sung ngữ cảnh khi KG thiếu thông tin.

Large Language Model	LLaMA-2, vLLM, PyTorch	Xử lý ngôn ngữ tự nhiên, tổng hợp kết quả từ KG và RAG để tạo ra câu trả lời mượt mà, thân thiện với người dùng cuối.

3. Chiến lược Dữ liệu

Dữ liệu là cốt lõi của tính chính xác. Đề tài áp dụng chiến lược thu thập và phân loại dữ liệu nghiêm ngặt, bao gồm các thành phần sau:

Dữ liệu tùy chỉnh (Custom Dataset): Được thu thập và làm sạch từ các văn bản pháp lý, hồ sơ địa giới, thông tin di tích lịch sử và các bài đánh giá du lịch thực tế.

Dữ liệu truy vấn (Complex Queries): Các bộ câu hỏi mẫu mang tính suy luận không gian (như khoảng cách, ranh giới) hoặc lịch sử đa chặng (sự thay đổi tên gọi di sản qua các triều đại).

Dữ liệu đối chuẩn (Benchmark Datasets): Kế thừa các bộ dữ liệu chuẩn như GS-QA, MapQA, Tourism QA để làm hệ quy chiếu đánh giá chéo hiệu năng của hệ thống.

4. Luồng Quy trình Thực thi (Execution Pipeline)

Khi người dùng đặt câu hỏi, hệ thống sẽ tự động thực thi chuỗi hành động 3 bước chặt chẽ sau để đưa ra câu trả lời:

- **Bước 1 - Phân tích câu hỏi (Question Processing):** Hệ thống phân loại truy vấn đầu vào thành các dạng: cần suy luận logic (hướng Đồ thị tri thức) hay cần truy xuất văn bản (hướng RAG). Tác vụ định tuyến (Router) này sử dụng các thuật toán máy học truyền thống như Naive Bayes hoặc Logistic Regression kết hợp TF-IDF. Việc này giúp hệ thống siêu nhẹ, phản hồi tức thời và có độ chính xác phân loại ý định (Intent Classification) cao hơn so với việc dùng LLM làm router.
- **Bước 2 - Lọc vật lý & Truy xuất ngữ nghĩa (Retrieval):** Dựa trên kết quả định tuyến, hệ thống thực thi truy vấn trực tiếp đồ thị (Neo4j) để lấy sự thật cứng. Nếu đồ thị thiếu thông tin, nhánh RAG sẽ kích hoạt để tính toán độ tương đồng Cosine trong FAISS và trích xuất top-k văn bản liên quan nhất từ Vector DB.
- **Bước 3 - Tổng hợp và Phát sinh câu trả lời (Cross-check & Generation):** Chuyển giao các thực thể từ Đồ thị tri thức và các văn bản top-k từ RAG vào

mô hình ngôn ngữ lớn (VinaLLaMA). LLM đối chiếu chéo lại các thông tin để đảm bảo tính trung thực (Faithfulness), sau đó sinh ra phản hồi hoàn chỉnh.

5. Đánh giá Hiệu năng (Evaluation)

Hệ thống được thiết kế để vượt qua các rào cản thông thường của LLM thông qua các chỉ số đo lường khắt khe:

Đánh giá Định lượng: Tập trung vào độ chính xác của luồng phân loại và truy xuất thông tin. Hiệu suất của hệ thống được đo lường bằng độ đo F1 (F1-score), với mục tiêu đạt từ **90% - 98%**. Công thức tổng quát được áp dụng:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Đánh giá Định tính: Câu trả lời sinh ra phải đáp ứng hai tiêu chí cốt lõi của kiến trúc RAG-LLM: Độ liên quan của ngữ cảnh (Context Relevancy) và tính trung thực tuyệt đối so với nguồn cung cấp (Faithfulness).

6. Trạng thái Môi trường Dev (Dev Environment Readiness)

Môi trường phát triển (Dev) đã sẵn sàng với các framework kỹ thuật dữ liệu quen thuộc:

Core Framework: Pytorch.

Môi trường suy diễn LLM: vLLM server.

Quản trị Vector & Đồ thị: Neo4j cục bộ và thư viện faiss-cpu/faiss-gpu (dùng cho lập chỉ mục FAISS).

Thư viện tiện ích xử lý: transformers, sentence-transformers (nhúng vector) và scikit-learn (cho module phân loại ý định). Dữ liệu thô thu thập sẽ đi qua luồng tiền xử lý để làm sạch và vector hóa bằng các công cụ này.

7. Kết luận

Việc tích hợp Đồ thị tri thức cùng RAG và LLM không chỉ giải quyết bài toán "ảo giác" muôn thuở của AI tạo sinh, mà còn mở ra một hướng đi mới cho việc số hóa và khai thác tri thức đặc thù tại Việt Nam. Bắt đầu từ lĩnh vực Di sản - Du lịch, kiến trúc nền tảng này hoàn toàn có tiềm năng mở rộng sang các bài toán phức tạp hơn như dịch vụ hành chính công hay hệ thống tra cứu pháp lý doanh nghiệp, đóng góp trực tiếp vào công cuộc chuyển đổi số quốc gia.